

دانشگاه اراک

دانشکده مهندسی صنایع

درس پروژه مقطع کارشناسی

رشته ی مهندسی صنایع گرایش بهینه سازی سیستم ها

پیش بینی تقاضای مصرف گاز مشترکین خانگی با سری زمانی با رویکرد یادگیری

عمیق(مورد مطالعاتی : شرکت گاز استان مرکزی)

دانشجو : فاطمه قلعه نویی

استاد راهنما : دکتر اشرف نوروزی

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ

فهرست

۷	۱-۱ مقدمه
۷	۲-۱ بیان مسئله
۸	۳-۱ محدودیت های پژوهش
۹	۴-۱ مفروضات مسئله
۹	۵-۱ نوآوری های پژوهش
۱۰	۶-۱ اهداف پژوهش
۱۲	۱-۲ مقدمه
۱۲	۲-۲ تعاریف و مفاهیم
۱۲	۱-۲-۲ پیش بینی تقاضا
۱۳	۲-۲-۲ فرآیند پیش بینی
۱۴	۳-۲-۲ انواع پیش بینی
۱۴	۴-۲-۲ عوامل تاثیرگذار در پیش بینی تقاضا
۱۵	۲-۴-۲-۲ رویدادهای تقویم
۱۵	۳-۴-۲-۲ فصلی بودن
۱۶	۴-۴-۲-۲ سری زمانی
۱۶	۱-۴-۴-۲-۲ انواع سری زمانی
۱۶	۵-۲-۲ یادگیری ماشین
۱۷	۳-۲ پژوهش های انجام شده در رابطه با این موضوع
۱۹	۱-۳ مقدمه
۲۰	۲-۳ جمع آوری داده ها و پیش پردازش
۲۰	۱-۲-۳ انتخاب مجموعه داده ها
۲۱	۲-۲-۳ آب و هوای شهر اراک
۲۱	۳-۲-۳ تقویم روزهای خاص سال
۲۱	۴-۲-۳ نرمال سازی داده ها
۲۱	روش های معمول نرمال سازی:
۲۲	۵-۲-۳ تقسیم داده های آموزش و آزمایش
۲۲	۳-۳ مدل ها پیش بینی و تنظیم مدل
۲۳	۱-۳-۳ مدل کلاسیک
۲۳	۲-۳-۳ دل میانگین متحرک خود همبسته یکپارچه فصلی
۲۳	۳-۳-۳ ایستایی و تفاضل
۲۵	۴-۳-۳ مدل خودرگرسیون
۲۵	۵-۳-۳ مدل های میانگین متحرک
۲۶	۶-۳-۳ مدل SARIMA
۲۷	۷-۳-۳ الگوریتم Adam

۲۸	 LSTM)) الگوریتم حافظه طولانی کوتاه مدت
۳۰	 معیار عملکرد
۳۰	 RMSE)) ریشه میانگین مربعات خطا
۳۱	 MAE)) میانگین خطای مطلق
۳۱	 روش پیشنهادی
۳۳	 مقدمه
۳۳	 سری زمانی چند متغیره
۳۵	 ۱-۲-۴ پیش پردازش داده ها
۳۶	 ۱-۲-۴ پاکسازی داده ها
۳۶	 ۲-۱-۲-۴ انتخاب ویژگی
۳۷	 ۲-۲-۴ ساخت مدل
۳۷	 SARIMA مدل ۱-۲-۲-۴
۳۹	 LSTM ۲-۲-۲-۴
۳۹	 ۳-۴ نتیجه گیری
۳۹	 ۴-۴ جمع بندی
۳۹	 ۵-۴ نتایج پژوهش
۴۷	 اهمیت پژوهش
۴۸	 مراجع
۵۱	 پیوست ها

تشکر و قدردانی

با سپاس و تقدیر ویژه از استاد گرانقدر سرکار خانم دکتر اشرف نوروزی که در مراحل مختلف این پژوهش، راهنمایی های ارزنده و سازنده خود را بر من ارزانی داشته و از هیچ کوششی در این زمینه دریغ ننمودند.

و نیز از شرکت گاز استان مرکزی که ما را در هر چه بهتر و کامل شدن این پروژه یاری کردند ، تشکر ویژه دارم.

چکیده

این پژوهش با هدف پیش‌بینی مصرف گاز مشترکین خانگی در شهر اراک در منطقه ۱ و ۲ انجام شده است. با توجه به اهمیت مدیریت بهینه منابع انرژی و برنامه‌ریزی دقیق برای پاسخگویی به تقاضای مشترکین، استفاده از روش‌های نوین هوش مصنوعی و یادگیری ماشین می‌تواند دقت پیش‌بینی را به شکل چشمگیری افزایش دهد. در این پروژه با بهره‌گیری از داده‌های ده‌ساله مصرف ماهانه مشترکین و اطلاعات هواشناسی شامل دما و بارش، مدل‌های پیشرفته یادگیری عمیق (LSTM) و مدل کلاسیک (SARIMA) طراحی و پیاده‌سازی شدند. نتایج به‌دست‌آمده با ۲۵ درصد داده آزمایشی و ۷۵ درصد داده آموزشی نشان می‌دهد که استفاده از روش‌های یادگیری عمیق، خطای پیش‌بینی را نسبت به روش‌های سنتی و کلاسیک به میزان قابل توجهی کاهش می‌دهد و می‌تواند به مدیران و برنامه‌ریزان شرکت گاز در مدیریت مصرف و تأمین پایدار انرژی کمک کند.

۱-۱ مقدمه

پیش بینی تقاضا امروزه مولفه ای مهم در ساخت زنجیره تامین و عاملی موثر در هزینه های مرتبط با موجودی و تامین تقاضا است. ایران با داشتن ۳۳/۶ تریلیون متر مکعب ذخایر اثبات شده (تقریبا برابر ۱۸ درصد کل ذخایر گاز دنیا) رتبه یک ذخایر گازی را دارا است [1]. درحالیکه رتبه چهارم را از نظر مصرف به خود اختصاص داده است که نشان از مصرف بالای گاز طبیعی در ایران میدهد . مطالعه [2] نشان میدهد در بین انرژی های اولیه مصرف گاز طبیعی بیشترین رشد را در سال های آینده خواهد داشت ، این رشد برای کشور های در حال توسعه بیشتر هم خواهد بود. در این شرایط با توجه به محدود بودن منابع گاز طبیعی به منظور پیشگیری از مواجهه با کمبود مدیریت صحیح مصرف گاز اهمیت بالایی دارد. عاملی موثر در مدیریت مصرف ، پیش بینی میزان مصرف یا تقاضای محصول و کنترل عوامل تاثیر گذار بر مصرف است. به دلیل نوسانات و کمبود گاز چند سال اخیر در کشور ارائه یک مدل دقیق و کارا به منظور پیش بینی تقاضا بیش از پیش اهمیت پیدا کرده است. این پژوهش سعی دارد با تمرکز بر مصرف گاز طبیعی مشترکین خانگی و با بکارگیری قابلیت های یادگیری ماشین این داده های سری زمانی مصرف گاز را پیش بینی و تحلیل کند.

۱-۲ بیان مسئله

از مشکلاتی که تولید کننده در زنجیره تامین با آن مواجه میشود پیش بینی تقاضا میتوان نام برد. به طور خاص برای انرژی های غیرطبیعی که نیاز اصلی و روزانه مردم هستند تعیین تقاضا برای این محصولات امری بسیار مهم و ضروری است [2]. تقاضای چنین محصولاتی در طول زمان دچار تغییر

گسترده و در مواقع ناگهانی دچار تغییر شده همچنین منابع محدودی برای انرژی های غیرطبیعی وجود دارند که نشان می دهد کمبود این محصول کشور را دچار بحران جدی میکند. در ایران روزانه مقدار قابل توجهی گاز طبیعی مصرف میشود که بخشی از این مصرف متعلق به مشترکین خانگی است لذا برای به کمبود نخوردن این مشترکین نیاز به پیش بینی دقیق از میزان مصرف این گروه است [3]. استفاده کارآمد از منابع انرژی به پیش بینی دقیق تقاضای انرژی در آینده بستگی دارد. بنابراین، محققان و متخصصان متعددی مسائل مختلف انرژی را تجزیه و تحلیل کرده و بر توسعه مدل های مناسب تقاضای انرژی تمرکز کرده اند که از زمان بحران نفت، میزان خطاهای پیش بینی را برای مصرف کارآمدتر منابع انرژی کاهش می دهند. این پیش بینی دقیق نیازمند بکارگیری یک مدل مناسب با خطای کم و در نظر گرفتن عوامل موثر بر تقاضا و توجه به تغییرات فصلی تقاضای گاز طبیعی است [4] چرا که نمیتوان ادعا کرد تقاضا در تمام روز ها و حتی در روز های خاص یکسان است بلکه دارای یک تابع الگوی فصلی است. به طور خاص تغییرات شرایط آب و هوایی و روز های خاص برای مثال تعطیلات عمومی عواملی هستند که باعث تغییر قابل توجهی در مصرف میشوند. چالش دیگر میتواند تغییرات ناگهانی شرایط آب و هوایی باشد که در فصل زمستان کشور را دچار بحران کمبود گاز میکند. تمام این عوامل را میتوان به عنوان پارامتر های موثر بر تقاضا بر شمرد.

۱-۳ محدودیت های پژوهش

پژوهشگران همواره دچار مواجهه با محدودیت هایی در پژوهش هستند. این تحقیق نیز محدودیت هایی به همراه دارد.

- ۱- عدم استفاده از تمام داده های کیفی و کمی تاثیر گذار بر روی مصرف گاز به دلیل عدم امکان اندازه گیری دقیق.

۲- با توجه به اینکه امکان ثبت داده های مصرف گاز به صورت روزانه وجود ندارد داده ها

مربوط به هر ۴۵ روز سال می باشد.

۴-۱ مفروضات مسئله

داده ها شامل میزان مصرف گاز حوزه یک و دو شرکت گاز استان مرکزی، داده های شرایط آب و

هوایی و همچنین روز های خاص ماه تقسیم میشود.

تقسیم بندی داده ها به سه دسته : دسته داده های آموزش، داده های آزمون و داده های اعتبار

سنجی تقسیم می شوند.

۵-۱ نوآوری های پژوهش

پژوهش های دیگری با پرداختن حول مسئله پیش بینی وجود دارد. اکثر این تحقیقات بر اساس مدل

های آماری سنتی مبتنی بر سری زمانی هستند ، خلاف این مدل های آماری مدل یادگیری ماشین

هیچ فرضی را در پیش بینی در نظر نمی گیرد. از طرف دیگر مدل یادگیری ماشین علاوه بر روابط

خطی بین متغیر ها توانایی مدل سازی روابط غیر خطی و پیچیده را هم دارد درحالیکه مدل های

آماری سنتی معمولاً فقط روابط خطی بین متغیر ها را در نظر میگیرد. گیل و دفراری [7] در مطالعات

خود از متغیرهای ورودی مختلفی برای ایجاد یک مدل استفاده کردند، اما می توان متوجه شد که

رایج ترین متغیرها، مصرف گاز طبیعی گذشته و داده های هواشناسی (به ویژه دما) بودند. داغبندان و

نسا [3] با در نظر گرفتن رابطه بین داده های شرایط آب و هوایی و میزان مصرف گاز نشان دادند در

نظر گرفتن رابطه بین این دو متغیر پیش بینی را دقیق تر میکند. لیو و لین [6] در مطالعات خود با در

نظر گرفتن سری زمانی فصلی و ماهانه به این نتیجه رسیدند که استفاده از داده های ماهانه دقیق تر

است با این حال داده های فصلی کارایی بیشتری دارند. همچنین مطالعات ماکریداکیس و همکاران [8] در زمینه ارزیابی مقایسه عملکرد چندین افق پیش‌بینی را با استفاده از زیرمجموعه بزرگی از ۱۰۴۵ سری زمانی ماهانه در نظر گرفته پس از مقایسه دقت پس از نمونه‌گیری روش‌های محبوب یادگیری ماشین با هشت روش آماری سنتی، به این نتیجه رسیده که روش‌های یادگیری ماشین در هر دو معیار دقت مورد استفاده و برای همه افق‌های پیش‌بینی مورد بررسی، غالب هستند. نوآوری این پژوهش سعی بر استفاده همزمان از این ویژگی‌های تاثیر گذار فوق‌الذکر بر میزان مصرف و تقاضا گاز طبیعی است

۱-۶ اهداف پژوهش

پیش‌بینی و تحلیل سری‌های زمانی همواره نقش کلیدی در تصمیم‌گیری و برنامه‌ریزی فعالیت‌های آتی دارد. امروزه استفاده از یادگیری ماشین در زمینه‌های مختلف پیش‌بینی تقاضا نقش گسترده‌ای پیدا کرده. لذا در این پژوهش داده‌های سری‌های زمانی را تحلیل و بررسی کرده و با بکارگیری ابزار یادگیری ماشین به پیش‌بینی تقاضا سری‌های زمانی می‌پردازیم.

اهداف ما در این پروژه به شرح زیر می‌باشد :

- ✓ جمع‌آوری داده‌ها ، پیش‌پردازش داده‌ها و انتخاب ویژگی‌ها
 - ✓ ساخت مدل یادگیری ماشین و مدل کلاسیک بر روی داده‌های جمع‌آوری شده برای پیش‌بینی تقاضا
 - ✓ تحلیل و بررسی داده‌های سری‌های زمانی و بررسی ویژگی‌های سری‌های زمانی بر روی داده‌ها
 - ✓ ارزیابی و اعتبار سنجی و بررسی میزان خطا مدل بر روی داده‌های سری‌های زمانی
- در این پژوهش داده‌های سری‌های زمانی چند متغیره هستند . روش کلاسیک میانگین متحرک یکپارچه خود همبسته فصلی (SARIMA) و روش پیشرفته حافظه طولانی کوتاه مدت (LSTM) مورد استفاده قرار گرفته.

فصل دوم

پیشینه پژوهش

در این فصل ابتدا به مرور مفاهیم پیش بینی تقاضا و تعریف پیش بینی ، سری زمانی و یادگیری ماشین پرداخته میشود و سپس مروری کلی به رویکردهای مرتبط با پژوهش حاضر در زمینه پیش بینی تقاضا شده است.

۲-۲ تعاریف و مفاهیم

۱-۲-۲ پیش بینی تقاضا

پیش بینی تقاضا نقش مهمی در مدیریت عملیات ها به عنوان ورودی برای فعالیتهای برنامه ریزی شده ایفا می کند. اثرات پیش بینی ضعیف شامل اتمام موجودی یا موجودی بالا، منسوخ شدن، سطح خدمات پایین، سفارشات عجله ای، استفاده ناکارآمد از منابع در زنجیره تأمین بالادستی است. به همین ترتیب، پیش بینی تقاضا یک موضوع تحقیقاتی محبوب است و مدل های زیادی برای پیش بینی محصولات مد در چند دهه گذشته ارائه شده است [6]. در چند دهه گذشته تکنیک های متعددی برای پیش بینی دقیق آینده مصرف انرژی توسعه یافته اند، دامنه کاربردها و تکنیک های پیش بینی بسیار گسترده است [7]. همچنین چوپرا و مایندل [10] اشاره میکنند که پیش بینی تقاضای یک عمل مهم در هر دو عملیات فشار و کشش زنجیره تأمین است که در آن تقاضاهای آینده برای برنامه ریزی فعالیتهای کارآمدتر پیش بینی می شوند. همچنین، پیش بینی تقاضا نقش کلیدی در برآورده کردن نیاز مشتری در فراینده تحویل کالا از طریق دستیابی به موقع منابع ایفا میکند [11]

۲-۲-۲ فرآیند پیش بینی

فرآیند پیش بینی را میتوان به چند قسمت تقسیم کرد

۱- تعریف مسئله

۲- جمع آوری داده

۳- تجزیه و تحلیل اولیه

۴- انتخاب و برازش مدل مناسب


۵- استفاده و ارزیابی مدل

همیشه مهم است که فرآیند پیش بینی با تعریف دلایل پیش بینی شروع شود. همان طور که توسط هاینسمن و همکاران [14] اشاره شده است تعریف مسأله پیش بینی مستلزم درک این موضوع است که چه کسانی به پیش بینی ها نیاز دارند، چگونه از پیش بینی ها استفاده خواهد شد چه نوع داده های گذشته موجود و در دسترس است و در چه افق زمانی پیش بینی ها انجام میشود و همچنین هزینه اجرای فرآیند پیش بینی چقدر خواهد بود. هنگامی که مسأله پیش بینی به وضوح تعریف شد، جمع آوری داده های تقاضای تاریخی میتواند اجرا شود. نوع داده ای که باید جمع آوری شود نه تنها کیفیت آنها بلکه تخصص افراد خبره در جمع آوری هم بسیار مهم و با اهمیت میباشد، سپس تجزیه و تحلیل داده های اولیه برای کشف ویژگیهای داده ها انجام میشود [12].

پس از تجزیه و تحلیل داده های تاریخی جمع آوری شده، گام بعدی انتخاب یک مدل پیش بینی مناسب است که با داده های تقاضا متناسب باشد فاز برازش مدل مجموعه جدیدی از مقادیر را ایجاد میکند که میتواند با مشاهدات اصلی مقایسه شود. هدف از این روش اندازه گیری خطاهای پیش بینی

است که برازش مناسب را بین مدل پیش بینی و داده های تقاضای مشاهده شده را تعیین میکند [12]. با داشتن یک انتخاب مدل مناسب ، به خوبی میتوان آن را در سریهای زمانی برازش داد و همین طور پیش بینی های جدیدی برای دوره های آینده ایجاد کرد در نهایت ارزیابی عملکرد مدل پیش بینی پس از دسترسی به داده های واقعی دوره های آینده امکان پذیر میباشد [12].

۳-۲-۲ انواع پیش بینی



شکل ۲-۱: انواع پیش بینی (۱۰)

۴-۲-۲ عوامل تاثیرگذار در پیش بینی تقاضا

عوامل زیادی بر روی تقاضا تاثیر می گذارند؛ برخی عوامل در کنترل تولیدکنندگان هستند مانند تبلیغات و محصولات جایگزین و برخی از عوامل چندان در کنترل تولیدکننده نیستند مانند فصلی بودن محصول ، آب و هوا و روزهای خاص اما دانستن این شرایط اجتناب ناپذیر مهم است.

۲-۲-۴-۱ آب و هوا

عرضه و تقاضا محصولات تحت تاثیر عواملی چون رطوبت ، دمای هوا و بارش بستگی دارد [13] . چالشی که در انتخاب متغیر آب و هوا وجود دارد طیف وسیعی از شرایط آب و هوایی است مانند بارش و نور خورشید که شامل میشود، با این وجود آب و هوا میتواند متغیر خوبی برای پیش بینی باشد [14].

۲-۲-۴-۲ رویدادهای تقویم

الگوی مصرف برای مصرف کننده ممکن است تحت تاثیر روز های خاصی از سال مانند تعطیلات قرار بگیرد. همچنین رویدادهای تقویم خاص را مانند عید نوروز را میتوان به عنوان فصلی مدل سازی کرد اما اعیاد اسلامی و تعطیلاتی که به مناسبت شهادت هستند که تاریخ ثابتی ندارند را فصلی نمیتوان تلقی کرد.

۲-۲-۴-۳ فصلی بودن

مصرف گاز مشترکین را میتوان ۴ فصل بهار ، تابستان ، پاییز و زمستان در نظر گرفت با این حال میتوان تعطیلات نوروز را به صورت فصلی و چرخه ۱۲ ماهه در نظر گرفت که فصلی بودن متناظر را ایجاد میکند [13] . مدل های مئرد استفاده در پیش بینی ، تقاضا در آنها رویکرد فصلی دارد و باید بتوانند الگوهای فصلی متعددی را پیش بینی کند

۲-۲-۴-۴ سری زمانی

سری زمانی به مجموعه‌ای از داده‌ها اطلاق می‌شود که به ترتیب زمانی و در فواصل منظم (روزانه، ماهانه، سالانه و...) جمع‌آوری شده‌اند. در این نوع داده‌ها، ترتیب زمانی نقش کلیدی دارد و هر مشاهده به زمان خاصی وابسته است. سری‌های زمانی در بسیاری از حوزه‌ها مانند اقتصاد، هواشناسی، انرژی، سلامت و علوم اجتماعی کاربرد دارند [15]. از ویژگی سری‌های زمانی میتوان به وابستگی زمانی (مقادیر جاری تحت تأثیر مقادیر گذشته هستند)، الگوهای تکراری (رفتارهای فصلی یا روندهای بلندمدت ممکن است ظاهر شوند) و نویز و تصادفی بودن داده‌ها (معمولاً دارای نوسانات غیرقابل پیش‌بینی نیز هستند) [15].

۲-۲-۴-۱ انواع سری زمانی

انواع سری‌های زمانی شامل سری زمانی ایستا، سری زمانی غیرایستا، سری زمانی فصلی و سری زمانی چندمتغیره.

۲-۲-۵ یادگیری ماشین

یادگیری ماشین، یعنی ساخت سیستم‌هایی که با مشاهده مثال‌ها یا تجربه، دانش عمومی یا تصمیم‌گیری را استخراج می‌کنند و سپس با تجربه بیشتر دقت و کارایی‌شان بهبود می‌یابد.

یادگیری ماشین به عنوان شاخه‌ای از هوش مصنوعی معرفی می‌شود که هدف آن ایجاد سیستم‌هایی است که خودآموزی از تجربه؛ بهبود با زمان، گونه‌های متنوع یادگیری، یادگیری القایی از مثال‌ها، یادگیری از طریق تجربه یادگیری مشاهده‌ای و کشف یادگیری از طریق دستور و آموزش و رویکرد چندجانبه [16].

۲-۳ پژوهش های انجام شده در رابطه با این موضوع

در این بخش به مروری بر روی پژوهش های گذشته در زمینه پیش بینی تقاضا پرداخته شده؛

با توجه به محدود بودن منابع انرژی و به منظور پیشگیری از مواجهه با بحران در آینده، مدیریت صحیح مصرف و تولید منابع گاز از اهمیت زیادی برخوردار است، به دلیل مولفه های مختلف تاثیرگذار لزوم بکارگیری یک مدل دقیق و کارا بیش از پیش احساس میشود. شفيعی و برادران [5] در مطالعات خود مصرف گاز را با استفاده از مدل رگرسیون زنجیره مارکوف خاکستری و مصرف سالیانه گاز را پیش بینی کرده اند که ایزار مناسبی برای داده های کم با نوسانات تصادفی است، مطالعه کاربردی پیش بینی مصرف سالیانه گاز نشان می دهد که مدل رگرسیون زنجیره مارکوف خاکستری بهبود یافته، دقت بیشتری نسبت به مدل های خاکستری، رگرسیون خاکستری و رگرسیون زنجیره مارکوف خاکستری دارد [5]. داغبندان و ستایش [3] به مدل سازی مصرف گاز طبیعی مشترکین خانگی در شهر رشت با استفاده از مدل شبکه عصبی GMDH چند هدفی پرداختند نتیجه بر این اساس بوده که به منظور مدل سازی، داده ها به دو دسته (۷۰٪ برای آموزش و ۳۰٪ برای آزمایش) تقسیم شده اند. نتایج حاصل از مدل سازی با داده های تجربی مقایسه گردید که ضریب تعیین ۰,۸۹۴۳ بوده و تطابق بسیار خوبی با نتایج تجربی نشان داده است [3].

فصل سوم

روش پژوهش

در این فصل به ارائه روند مطالعه تجربی پرداخته خواهد شد. همان طور که در دو فصل قبل بیان شد مسائل سری زمانی در زمینه های مختلف با طیف وسیعی از کاربردها ظاهر میشوند در این فصل عملکرد و تطبیق پذیری چند مدل ارائه شده . مسأله پیش بینی مصرف گاز با استفاده از داده های قبلی و با بکارگیری داده های هواشناسی و در نظر گرفتن زمان های خاص تقویم به صورت دوره ای یک مسئله سری زمانی چند متغیره محسوب میشود که در آن عوامل خارجی یا همان ویژگیهای مورد استفاده در مجموعه داده ها بر عملکرد مدلهای تأثیر گذار خواهند بود، در این فصل سری زمانی چند متغیره با هدف درک این موضوع که کدام یک از ویژگیهای در عملکرد مدلهای مورد بررسی نتایج بهتری به بار می آورند مورد آزمایش قرار خواهد گرفت.

برای حل مسأله پیش بینی تقاضای انرژی از طرف مصرف کنندگان خانگی ، باید جنبه های مختلفی را مورد بررسی قرار داد. راه حل پیشنهادی برای مقابله با این مسأله شامل دو مرحله است:

جمع آوری داده ها و پیش پردازش منابع برای داده های ورودی مناسب موردنیاز برای هدف مدل سازی یافت میشود. مقادیر از دست رفته باید به درستی مدیریت شوند این امر بسیار مهم است زیرا روشهای صحیح باید انتخاب شوند، در غیر این صورت حذف کامل مقادیر از دست رفته میتواند سوگیری را به مدل پیش بینی اضافه کند.

مدلهای پیش بینی و تنظیم مدل مدلهای پیش بینی مختلفی توسعه یافته اند پارامترهای بهینه با استفاده از تنظیم فرا پارامتر انتخاب میشوند.

در ادامه توضیحی برای دو مجموعه داده ارائه میشود که در آن روش شناسی مورد استفاده در هر دو مسأله برای مقایسه مدلها نیز ارائه خواهند شد. روش شناسی برای همه مدلها یکسان است تا مقایسه عادلانه و صحیحی بین آنها وجود داشته باشد. قبل از آن، برخی از شیوه های مورد استفاده در هر دو مسأله توضیح و مورد بررسی قرار خواهند گرفت. نمودارهای مختلف برای از سرگیری روش مورد استفاده و همچنین استراتژی آموزشی اعمال شده برای آموزش مدلها در هر دو مجموعه داده، در معرض دید قرار می گیرند. همه آزمایشها در پایتون و مدلهای یادگیری ماشین از tensor flow توسعه داده شدند

۲-۳ جمع آوری داده ها و پیش پردازش

مطابق با اهداف پژوهش، این بخش به معرفی جزئیات داده های موجود مراحل تهیه و همچنین آماده سازی داده ها قبل از استفاده در مدل های مطرح شده پرداخته خواهد شد. لازم به ذکر است که امکان ثبت مصرف گاز خانوار به صورت روزانه وجود ندارد و هر ماه میزان مصرف گاز از طریق کنتور ها بررسی میشود.

۱-۲-۳ انتخاب مجموعه داده ها

داده های جمع آوری شده مربوط به حوزه ۱ و ۲ شرکت گاز استان مرکزی است. همانطور که مطرح شد داده ها مربوط به مصرف گاز مشترکین خانگی است و شامل مصرف شرکت ها و کارخانه ها نمیشود. میزان مصرف گاز از بهار سال ۱۳۹۵ تا اردیبهشت ماه سال ۱۴۰۴ گردآوری شده اند به مدت ۱۰ سال و ماهانه به همراه ویژگی هایی؛ شرایط آب و هوایی و روزهای خاص به عنوان مبنای داده های این پروژه انتخاب شده اند.

۲-۲-۳ آب و هوای شهر اراک

داده های آب و هوایی شهر از سایت www.weatherapi.com بدست آمده است. این داده های آب و هوایی شامل چهار پارامتر میانگین دما، بیشترین دما، کمترین دما (به درجه سانتی گراد) و بارندگی (به میلی متر) در هر ماه است.

۳-۲-۳ تقویم روزهای خاص سال

یکی از عوامل تاثیرگذار بر روی مصرف انرژی به خصوص گاز ایام تعطیل سال است. در اینجا تعطیلاتی که در طول خاص به صورت دوره ای در یک زمان معین تکرار شده اند (تعطیلا عید نوروز) در نظر گرفته شده؛ همچنین ویژگی هایی همچون فصل های سال و ماه های سال به عنوان دیگر ویژگی هایی که بر روی مصرف گاز خانگی تاثیر میگذارند در نظر گرفته شده.

۴-۲-۳ نرمال سازی داده ها

نرمال سازی یا مقیاس گذاری یک ویژگی پیش پردازش است که امری ضروری برای یکسان کردن مقیاس های متفاوت بین ویژگی ها است، بدون یکسان سازی ویژگی هایی که مقادیر بزرگ تری دارند تاثیر بیشتری بر روی پیش بینی میگذارند.

روش های معمول نرمال سازی:

مقیاس گذاری min-max (۱-۳) همه مقادیر را به یک محدوده ثابت، معمولاً بین [0,1] مقیاس بندی می کند.

$$X_{\text{نرمال}} = \frac{X - \mu_{\text{داده}}}{\sigma_{\text{داده}}} \quad (1-3)$$

مقیاس بندی استاندارد (۲-۳) یکی دیگر از روش های بسیار رایج مقیاس بندی است که داده ها را حول صفر با واریانس واحد متمرکز می کند که μ و σ به ترتیب میانگین و واریانس هستند.

$$X_{\text{نرمال}} = \frac{X - \mu_{\text{داده}}}{\sigma_{\text{داده}}} \quad (۲-۳)$$

۵-۲-۳ تقسیم داده های آموزش و آزمایش

دقت مدل را از روی عملکرد مدل بر روی داده های پیش پردازش شده میتوان اندازه گرفت. بنابراین تقسیم داده ها قبل از پردازش به دو دسته آموزشی و آزمایشی یک مرحله بسیار مهم در یادگیری ماشین است. این تقسیم بندی در داده های سری زمانی نمی تواند به صورت تصادفی باشد. در این مطالعه داده ها به نسبت ۷۵ درصد متعلق به داده های آموزشی و ۲۵ درصد متعلق به داده های آزمایشی دارد.

۳-۳ مدل ها پیش بینی و تنظیم مدل

در این بخش مدل های مطرح شده برای پیاده سازی بر روی مجموعه داده های موردنظر تشریح شده است. از آنجایی که داده های مصرف ماهانه گاز خانگی را می توان به عنوان داده های سری زمانی در نظر گرفت، در این پژوهش دو مورد از رایج ترین و مهم ترین روش های پیش بینی سری های زمانی ارائه شده است. و همچنین روش های مطرح شده را به دودسته مدل های کلاسیک و مدل های یادگیری عمیق تقسیم بندی شده است. به طور دقیق تر، SARIMA به عنوان مدل کلاسیک، LSTM به عنوان مدل های یادگیری عمیق برای ارائه پیش بینی تقاضا انتخاب شده اند.

۳-۳-۱ مدل کلاسیک

به زبان ساده، پیش بینی آماری به معنی استفاده از آمار بر اساس داده های تاریخی برای پیش بینی آنچه ممکن است در آینده رخ دهد، است [15]. مقادیر آینده سری های زمانی تا زمانی که مشاهده نشوند ناشناخته هستند و بنابراین مانند متغیرهای تصادفی هستند. متغیرهای تصادفی امکان بسیاری از نتایج بالقوه را فراهم میکنند با نزدیک شدن رویداد واقعی، عدم قطعیت در مورد نتایج بالقوه آن کاهش میابد، این دیدگاه آماری مدل های کلاسیک است [15].

۳-۳-۲ دل میانگین متحرک خود همبسته یکپارچه فصلی

مدل SARIMA را میتوان ترکیبی از یک مدل پیچیده و ساده در نظر گرفت که می تواند برای سری های زمانی نا ایستا با تغییرات فصلی به کار گرفته شود مدل میانگین متحرک یکپارچه خود رگرسیون (ARIMA) همراه با هموارسازی نمایی، دو مدل پرکاربرد برای پیش بینی سری های زمانی هستند [18]. در حالی که هموارسازی نمایی مبتنی بر یافتن و توصیف روند و فصلی بودن داده ها است ARIMA بر یافتن همبستگی خود در داده ها تمرکز دارد. [18] برای استفاده از داده های غیر ایستا مدل ARIMA تفاوتهایی را برای داده های سری زمانی اعمال میکند و داده های غیر ثابت را ثابت میکند [18].

۳-۳-۳ ایستایی و تفاضل

سری زمانی ثابت سری زمانی است که ویژگی های آماری آن به زمانی که سری در آن مشاهده میشود بستگی ندارد [19]. به همین دلیل سری زمانی فصلی ثابت نیستند، اندرسون و ویلیامز به این موضوع اشاره کرده اند که با اینکه سری زمانی ثابت همیشه روند افقی خواهد داشت، داشتن روند افقی

همیشه به معنای ثابت بوده سری زمانی نیست [20]. بسیاری از مدل‌های آماری کلاسیک مانند ARIMA و حتی برخی مدل‌های یادگیری ماشین، فرض می‌کنند که سری زمانی دارای خواص ایستایی باشد؛ بدین معنا که ویژگی‌هایی نظیر میانگین، واریانس و همبستگی در طول زمان ثابت باقی بمانند. با این حال، بسیاری از داده‌های دنیای واقعی، از جمله مصرف انرژی، دارای روند و فصل‌پذیری هستند و بنابراین نایستاتر تلقی می‌شوند. یکی از روش‌های رایج و موثر برای حذف روند و ایستاسازی سری زمانی، تفاضل‌گیری است. برای مقابله با مشکل ایستایی، تفاضل روشی است که در آن یک سری زمانی فصلی یا یک سری زمانی با روند با محاسبه تفاوت بین مشاهدات متوالی به یک سری زمانی ثابت تبدیل می‌شود [19].

روش تفاضل‌گیری برای حذف روند:

$$y_t' = y_t - y_{t-1} \quad (1-3)$$

که در آن y_t مقدار اصلی در زمان t در سری زمانی است و y_t' مقدار جدید پس از زمان تفاضل‌گیری است، این عمل، روند خطی موجود در داده را حذف کرده و نوسانات را نسبت به تغییرات زمانی بررسی‌پذیر می‌کند. در بعضی مواقع ممکن است پس از تفاضل مرتبه اول، روند همچنان باقی بماند در این صورت می‌توان از تفاضل مرتبه دوم استفاده کرد.

$$y_t'' = y_t' - y_{t-1}' = y_t - 2y_{t-1} + y_{t-2} \quad (2-3)$$

که در آن y_t' تفاوت بین هر مشاهده با سری قبلی است. تفاوت حاصل از تفاوت بین یک فصل و فصل قبلی است.

۳-۳-۴ مدل خودرگرسیون

یکی از ابتدایی‌ترین و در عین حال مؤثرترین این مدل‌ها، مدل خودرگرسیون است که فرض می‌کند مقدار فعلی یک متغیر به صورت خطی به مقادیر گذشته خود وابسته است. این مدل مبنای بسیاری از مدل‌های پیشرفته‌تر مانند ARMA و ARIMA را تشکیل می‌دهد.

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t \quad (3-3)$$

که در اینجا :

- y_t مقدار متغیر در زمان t است
- C مقدار ثابت .
- ϕ_i ضرایب مدل که نشان‌دهنده اثر مقادیر قبلی هستند
- P مرتبه مدل (AR) تعداد تأخیرها
- ε_t خطای تصادفی سفید با میانگین صفر و واریانس ثابت (white noise)

۳-۳-۵ مدل‌های میانگین متحرک

در مدل‌سازی سری‌های زمانی، دو دسته کلی از وابستگی‌ها وجود دارد، وابستگی به مقادیر گذشته متغیر (مدل خودرگرسیونی - (AR)) و وابستگی به خطاهای گذشته یا شوک‌های تصادفی (مدل میانگین متحرک - (MA)). مدل میانگین متحرک که به اختصار MA نامیده می‌شود، یک مدل آماری است که تغییرات سری زمانی را بر اساس ترکیبی خطی از نویزهای تصادفی گذشته (خطاهای قبلی) مدل‌سازی می‌کند. این مدل اغلب در کنار مدل AR در چارچوب ARMA یا ARIMA استفاده می‌شود.

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q} \quad (4-3)$$

که در آن:

- y_t مقدار متغیر در زمان t
- μ میانگین سری زمانی (در بسیاری از موارد برابر با صفر در مدل سازی)
- θ_i ضرایب مدل MA
- ε_t نویز تصادفی سفید (white noise)
- q مرتبه مدل (MA) تعداد خطاهای قبلی که مدل در نظر می گیرد

۳-۳-۶ مدل SARIMA

مدل SARIMA یا Seasonal ARIMA، نسخه‌ی گسترش یافته‌ی مدل ARIMA است که برای داده‌های فصلی در سری‌های زمانی استفاده می‌شود. این مدل، علاوه بر در نظر گرفتن خودرگرسیون، میانگین متحرک، و تفاضل‌گیری، اجزای فصلی را هم مدل سازی می‌کند. به صورت کلی مدل SARIMA با نماد زیر نمایش داده می‌شود: $SARIMA(p, d, q) \times (P, D, Q, s)$

که چهار مولفه اصلی برای پیکر بندی آن لازم است:

- p : مرتبه‌ی جزء خودرگرسیونی (AR)
- d : درجه‌ی تفاضل‌گیری برای ایستا کردن سری (non-seasonal differencing)
- q : مرتبه‌ی جزء میانگین متحرک (MA)

و برای جزء فصلی:

- P : مرتبه‌ی خودرگرسیونی فصلی
- D : درجه‌ی تفاضل‌گیری فصلی
- Q : مرتبه‌ی میانگین متحرک فصلی
- S : تناوب فصلی (مثلاً برای داده‌های ماهانه با چرخه‌ی سالانه ، $s=12$)

۷-۳-۳ الگوریتم Adam

الگوریتم Adam مخفف Adaptive Moment Estimation است. این الگوریتم یک روش بهینه‌سازی مبتنی بر گرادیان است که برای به‌روزرسانی وزن‌های شبکه‌های عصبی مورد استفاده قرار می‌گیرد. این روش با استفاده هم‌زمان از میانگین‌های متحرک درجه اول و درجه دوم (واریانس گرادیان‌ها)، نرخ یادگیری را به صورت تطبیقی برای هر پارامتر تنظیم می‌کند

الگوریتم Adam یک روش بهینه‌سازی مبتنی بر گرادیان است که برای به‌روزرسانی وزن‌های شبکه‌های عصبی مورد استفاده قرار می‌گیرد. این روش با استفاده هم‌زمان از میانگین‌های متحرک درجه اول (momentum) و درجه دوم (واریانس گرادیان‌ها)، نرخ یادگیری را به صورت تطبیقی برای هر پارامتر تنظیم می‌کند.

فرمول کلی به‌روزرسانی پارامترها در Adam به صورت زیر است:

محاسبه گرادیان:

$$g_t = \nabla_{\theta} J(\theta_t) \quad (5-3)$$

به‌روزرسانی میانگین متحرک گرادیان :

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (6-3)$$

به روزرسانی میانگین متحرک مربع گرادیان:

$$t v = \beta_2 v_{t-1} + (1 - \beta_2) g_t \quad (7-3)$$

اعمال تصحیح اریب :

$$\frac{t v}{\beta_2 - 1} = \hat{t} v, \quad \frac{t m}{\beta_1 - 1} = \hat{t} m \quad (8-3)$$

به روزرسانی پارامترها:

$$\frac{\hat{t} m}{\varepsilon + \sqrt{t v}} \alpha - \theta_t = \theta_{t+1} \quad (9-3)$$

که در آن :

θ : پارامترهای مدل

α : نرخ یادگیری (learning rate)

β_1, β_2 : پارامترهای نمایی کاهش (decay rates)

ε : عدد کوچک برای جلوگیری از تقسیم بر صفر

۳-۳-۸ الگوریتم حافظه طولانی کوتاه مدت (LSTM)

حافظه طولانی کوتاه مدت در سال ۱۹۹۷ معرفی شد و به ویژه برای مقابله با وابستگی های طولانی مدت در معماری های بازگشتی طراحی شد [20]. ایده اصلی معرفی حلقه های برای تولید مسیرهایی است که گرادیان میتواند در آن جریان داشته باشد. ایده اصلی پشت ها معرفی حالت سلولی است که در آن توانایی افزودن یا حذف اطلاعات به آن را دارد و به عنوان حافظه عمل میکند [20]. ها سه مورد از این واحدها هستند گیت های فراموشی، ورودی و خروجی گیت فراموشی، این گیت وظیفه دارد تصمیم بگیرد چه اطلاعاتی را باید از حالت سلولی دور انداخت یا به عبارت دیگر فراموش کرد [20].

$$f^{(t)} = \sigma(W_f * (h^{(t-1)}, x^{(t)}) + b_f) \quad (10-3)$$

گیت ورودی، هدف این گیت این است که تشخیص دهد چه اطلاعاتی در حالت سلولی باید قرار بگیرد. این بخش شامل دو قسمت است یک لایه سیگموئید که مسئول پیدا کردن مقداری است که وضعیت سلول را با آن بروز رسانی کند و لایه دیگر تانژانت هیپربولیک است یک برداری از نامزد های جدید برای تغذیه سلول فراهم میکند. هدف این بخش این است که شبکه بتواند تشخیص بدهد کدام اطلاعات مربوط به ذخیره وضعیت سلول است.

$$i^{(t)} = \sigma(W_i * (h^{(t-1)}, x^{(t)}) + b_i) \quad (11-3)$$

$$\tilde{c}^{(t)} = \tanh(W_c * (h^{(t-1)}, x^{(t)}) + b_c)$$


پس از به روز رسانی وضعیت سلول با توجه به مراحل

که باید انجام دهد ، وضعیت سلول در خروجی گیت فراموشی ضرب میشود و سپس اطلاعات جدیدی که تصمیم بهسپس اطلاعات جدیدی که تصمیم به روزرسانی وضعیت سلول گرفته شده را وارد میکنیم.

$$C^{(t)} = f^{(t)} * C^{(t-1)} + i^{(t)} * \tilde{C}^{(t)} \quad (12-3)$$

گیت خروجی ، هدف گیت خروجی این است که چه چیز را برای مرحله بعدی از حالت پنهان $h(t)$ عبور بدهد. این حالت فیلتر شده توسط یک لایه سیگموئید محاسبه میکند که چه بخش هایی از حالت های سلول برای خروجی ارسال بشوند به کمک لایه تانژانت هیپربولیک. که حالت سلول را در مقادیری بین ۱ و -۱ میرساند.

$$h^{(t)} = O^{(t)} * \tanh (C^{(t)}) \quad (13-3)$$



شکل (3-14) :

حافظه طولانی کوتاه مدت

۳-۴ معیار عملکرد

انتخاب معیار برای ارزیابی عملکرد مدل های یادگیری بسیار ضروری است. معیار ها بر نحوه اندازه گیری عملکرد الگوریتم های یادگیری ماشین و مقایسه الگوریتم ها با یکدیگر تاثیر زیادی میگذارند. معیار های عملکردی که در پژوهش برای مدل های پیاده سازی شده استفاده شده است عبارتند از : ریشه میانگین مربعات خطا (RMSE)، میانگین خطای مطلق (MAE) و P-VALUE است.

۳-۴-۱ ریشه میانگین مربعات خطا (RMSE)

RMSE جذر میانگین مجذور اختلاف بین مقادیر واقعی خروجی و پیش بینی شده است. زمانی که خطاهای بالا مطلوب نیستند این معیار عملکرد استفاده میشود. RMSE بالاتر به معنای خطای بیشتر و مدل بدتر است که به صورت زیر محاسبه میشود:

$$RSME = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (15-3)$$


۳-۴-۲ میانگین خطای مطلق (MAE)

میانگین خطای مطلق یک روش رایج برای اندازه گیری دقت پیش بینی است. تفاوت بین مقادیر خروجی واقعی و پیش بینی شده به مقادیر واقعی تقسیم میشود و میانگین این نسبت ها برای هر خروجی گرفته می شود و خطا را بیان میکند. این رایج ترین روش برای مسائل اندازه گیری است به خصوص اگر داده های دور افتاده وجود نداشته باشند.

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{(y_i - \hat{y}_i)}{y_i} \right| \quad (16-3)$$

۳-۴-۳ روش پیشنهادی

در این بخش روش های پیشنهادی مورد استفاده و فرآیند پیش بینی در پژوهش به صورت تصویری در شکل (۳-۱۷) آورده شده است.



شکل (۳-۱۷): فرآیند پیش بینی سری زمانی چند متغیره مصرف گاز مشترکین خانگی شهر اراک

فصل چهارم


یافته های پژوهش

۴-۱ مقدمه


همان طور که در فصل قبل مطرح شد هدف این پژوهش پیش بینی و تحلیل سری زمانی به صورت چند متغیره مصرف گاز مشترکین خانگی شهر اراک است. مدل های معرفی شده و مجموعه داده های معرفی شده در فصل سوم با یکدیگر مقایسه میشوند. نتایج برای هر مجموعه داده ارائه و تجزیه و تحلیل خواهند شد. در الگوریتم بهینه سازی و همچنین نرخ یادگیری، اندازه دسته و الگوریتم مورد بررسی قرار خواهند گرفت.

۴-۲ سری زمانی چند متغیره

سری زمانی چند متغیره به طور کامل در فصل سوم توضیح داده شده. قصد سری زمانی چند متغیره در این پژوهش پیش بینی مصرف با استفاده از عوامل خارجی میباشد که میتواند تاثیر زیادی بر مصرف بگذارد. همچنین برای پیش بینی و تحلیل میزان مصرف مورد نظر از عوامل خارجی برای افزایش کیفیت عملکرد از مدل یادگیری عمیق که زیر مجموعه یادگیری ماشین است استفاده خواهد شد. مصرف ماهانه گاز مشترکین خانگی در شهر اراک به مدت یک سال در شکل ۴-۱ و ده سال در شکل ۴-۲ نمایش داده شده.




شکل ۲-۴: مصرف ماهانه گاز خانگی شهر اراک به مدت ۱۰ سال برای پیش بینی سری زمانی چند متغیره



شکل ۳-۴: مصرف ماهانه گاز خانگی شهر اراک به مدت ۱۰ سال برای پیش بینی سری زمانی چند متغیره

در شکل ۳-۴ ماتریس همبستگی بین متغیر های عددی نشان داده شده است.



شکل ۴-۳: ماتریس همبستگی بین متغیرهای عددی

۴-۲-۱ پیش پردازش داده ها


با توجه به سری زمانی داده ها با طول ۱۰ سال باید پیش پردازش داده ها انجام شود. تمیز کردن داده ها و انتخاب ویژگی دو کار ضروری آماده سازی داده ها است که برای آماده سازی پیش بینی و تحلیل سری زمانی های چند متغیره به کار خواهد گرفته شد.

۴-۲-۱-۱ پاکسازی داده ها

در صورتی که داده ها دارای مقادیر از دست رفته و یا گمشده باشند، مقادیر دور افتاده هموار میشوند و مقادیر گمشده با تکنیک مناسب جایگزین میشوند. در مسئله مورد نظر تمان داده های مصرف گاز گرفته شده و داده گمشده ای وجود ندارد.

۴-۲-۱-۲ انتخاب ویژگی

یکی از مهم ترین مواردی که در پیش بینی سری زمانی چند متغیره میتوان نام برد انتخاب ویژگی است. چون همیشه ویژگی بیشتر باعث افزایش کارایی مدل نخواهد شد بلکه گاهی امکان دارد برعکس عمل واقع عمل شود [19]. در ادامه از روش انتخاب ویژگی الگوریتم XGBOOST برای مدل شبکه تعداد درخت تقویت ۵۰۰ و حداکثر عمق درخت ۱۷ است. در نهایت خروجی در شکل ۴-۴ نشان داده شده.



شکل ۴-۴: نتایج انتخاب ویژگی با استفاده از مدل XGBOOST

همانطور که در شکل ۴-۳ مشاهده میکنید پارامتر فصل و بعد از آن میانگین دما بیشترین تاثیرگذاری را در میزان مصرف گاز دارند. و به ترتیب بیشترین دما و کمترین دما در حوزه ۱ بیشترین تاثیرگذاری را دارند در ادامه برای حل مسئله سری زمانی چند متغیره از تمامی این ویژگی ها استفاده شده.

۴-۲-۲ ساخت مدل

در این بخش به فرآیند مدل سازی و همچنین خروجی مدل های مدنظر پرداخته شود.


۴-۲-۲-۱ مدل SARIMA

برای پیاده سازی مدل SARIMA پس از ثابت کردن داده ها با روش تفاضل گیری از تابع خودهمبستگی استفاده شده. تابع خودهمبستگی (ACF) همبستگی میان مقدار های سری زمانی را برحسب تاخیر دلخواه مشخص میکند. این تابع به تشخیص پارامتر مدل سری زمانی خود رگرسیون AR کمک میکند. همانطور که در شکل ۴-۵ مشاهده میشود نمودار خودهمبستگی میزان مصرف برحسب تاریخ نشان داده شده دومرحله اساسی در SARIMA پیدا کردن ترتیب متفاوت پارامتر های (D,d) و انتخاب دستورات عملگر های AR,MR است. یکی از روش ها به منظور شناسایی بهتر

این پارامترها از نمودار خودهمبستگی (ACF) و خودهمبستگی جزئی (PACF) که در شکل ۴-۵ است. با مقایسه دامنه این دو نمودار میتوان قسمت خودرگرسیون و میانگین متحرک (P,q) را تعیین کرد.

شکل ۴-۴: نمودار خودهمبستگی (ACF) و خودهمبستگی جزئی (PACF)


با استفاده از ترسیم نمودارهای خودهمبستگی (ACF) و خودهمبستگی جزئی (PACF) میتوان پارامترهای الگوهای فصلی و غیرفصلی را پیدا کرد بدین ترتیب بهترین پارامترها برای SARIMA به ترتیب



شکل ۴-۵: مقایسه میان داده های آموزشی و آزمایشی با داده های تست آموزشی

برابر SARIMA (1, 1, 2) (1, 1, 1, 12) نشان میدهد. در شکل ۴-۵ مقایسه میان داده های آموزشی و آزمایشی با داده های تست آموزشی را مشاهده میکنید.

داده ها به ۷۵ درصد آموزشی و ۲۵ درصد آزمایشی تقسیم بندی شده اند در شکل ۴-۶ پیش بینی ۱۲ ماه آینده و مقایسه با داده های گذشته را مشاهده میکنید.




شکل ۴-۶: پیش بینی ۱۲ ماه آینده و مقایسه با داده های گذشته

مقادیر معیار های عملکردی مقادیر RMSE و MAE و MAPE در داده های آموزشی به ترتیب برای حوزه ۱، ۳۴۵۲۳۵۶۸۸۶۳۰۸۹،۶۵۲، ۴۹۱۵۲۹۲،۲۲۴۷۰۰۸۰۲ و ۱۰،۱۸۷۳۶۸۴۰۳۳۳۶۴۲۱٪ بدست آمده است.

LSTM ۲-۲-۲-۴

شبکه عصبی LSTM یکی از پرکاربردترین مدل ها در حوزه پیش بینی است. در شکل ۴-۷ معماری مورد استفاده در این بخش و همچنین مقادیر پارامتر های در نظر گرفته شده در مسئله سری زمانی چند متغیر در جدول ۴-۸ نشان داده شده است.



شکل ۴-۷: معماری مدل LSTM در مسئله سری زمانی چند متغیره

Dense	2
تابع فعال ساز	$\tanh$, sigmoid
بهینه سازی	adam
نرخ یادگیری	$3e-4$
اندازه دسته	16
اندازه epoch	300

شکل ۴-۸: مقادیر مشخص شده برای هر فرا پارامتر مدل LSTM در مسئله سری زمانی چند متغیره


پس از آموزش مدل متناسب با مقادیر و همچنین عملیات آزمون مدل مقادیر معیار های عملکردی

مقادیر RMSE و MAE و R2 در داده های آموزشی به ترتیب برای حوزه ۱، ۱۶۷، ۴۶۷۸۱۵۰،


۳۸۵۵۶۱۵، ۸۱۵، ۰،۹۲۸ بدست آمده است. در شکل ۴-۹ مقایسه میان مقدار واقعی حوزه ۱ و ۲ با

مقدار پیش بینی شده نشان داده شده است. و در شکل ۴-۱۰ مقایسه ای میان مقادیر پیش بینی

شده بین دو حوزه ۱ و ۲ صورت گرفته است.




شکل ۴-۹: مقایسه میان مقدار واقعی حوزه ۱ و ۲ با مقدار پیش بینی شده




شکل ۴-۱۰: مقایسه بین مقادیر پیش بینی شده بین دو حوزه ۱ و ۲ به مدت ۵ ماه

نمودار scatter برای مقایسه مقدار مصرف واقعی و پیش بینی شده را می‌توان به حالت رگرسیونی برای حوزه ۱ در شکل ۴-۱۱ و در شکل ۴-۱۲ برای حوزه ۲ مشاهده کرد.



شکل ۴-۱۱: نمودار رگرسیونی مقایسه مصرف واقعی با مصرف پیش بینی شده در حوزه ۱



شکل ۴-۱۲: نمودار رگرسیونی مقایسه مصرف واقعی با مصرف پیش بینی شده در حوزه ۲

۳-۴ نتیجه گیری


در این بخش به تحلیل مقایسه‌ای و بررسی نتایج پیش‌بینی مدل‌های موردنظر در دو حوزه پرداخته می‌شود. خروجی‌های حاصل از به‌کارگیری مدل‌های سری زمانی چندمتغیره نشان می‌دهد که در حوزه ۱، مدل LSTM به‌عنوان یک الگوریتم شبکه عصبی مبتنی بر یادگیری عمیق، در هر دو شاخص عملکردی RMSE و MAE عملکرد بهتری نسبت به مدل SARIMA که یک الگوریتم کلاسیک محسوب می‌شود، داشته است. همان‌گونه که در شکل (۴-۹) مشاهده می‌شود، مقادیر پیش‌بینی‌شده مصرف در حوزه ۱ تطابق قابل قبولی با مقادیر واقعی دارد. علاوه بر این، نمودار رگرسیونی ارائه‌شده در

شکل (۴-۱۱) نشان می‌دهد که داده‌ها پراکندگی زیادی نداشته و از پیوستگی مناسبی برخوردارند. همچنین مقدار بالای R^2 در این حوزه نشان‌دهنده کارایی مطلوب و استاندارد بودن مدل است.

در مقابل، در حوزه ۲ هر دو مدل LSTM و SARIMA نتایج چندان مطلوبی ارائه نکرده‌اند؛ به‌طوری‌که مقادیر شاخص‌های RMSE و MAE بسیار بزرگ و نامناسب گزارش شده‌اند. مطابق شکل (۴-۱۲)، پیش‌بینی‌های مدل LSTM در این حوزه با پراکندگی قابل‌توجهی همراه بوده و به دلیل وجود داده‌های پرت، این الگوریتم توانایی مناسبی در برازش الگو از خود نشان نداده است. علاوه بر این، همان‌طور که در شکل (۴-۱۳) مشخص است، مقادیر بالا در شاخص‌های RMSE، MAE و MAPE برای مدل SARIMA حاکی از آن است که پیش‌بینی دقیق و قابل‌اعتماد مصرف‌گاز در حوزه ۲ امکان‌پذیر نیست. در شکل (۴-۱۰) نیز مقایسه پیش‌بینی مصرف‌گاز در حوزه‌های ۱ و ۲ با استفاده از الگوریتم LSTM برای یک بازه زمانی پنج‌ماهه ارائه شده است. بر اساس روند نمودار، پیش‌بینی می‌شود که در اواسط مهرماه مصرف‌گاز در حوزه ۱ به‌طور قابل‌توجهی افزایش یابد. با این حال، در حوزه ۲ به دلیل تعداد کمتر مشترکین نسبت به حوزه ۱، داده‌های مصرف‌گاز پراکندگی بالایی دارند و این امر موجب کاهش دقت و قابلیت اعتماد مقایسه نتایج بین دو حوزه می‌شود. در حالی‌که در حوزه ۱ به دلیل تعداد زیاد مشترکین و نبود داده‌های مفقود یا پراکنده، مدل‌سازی و پیش‌بینی سری زمانی از دقت و قابلیت اتکای بیشتری برخوردار است.

مقادیر	R2	MAPE	MAE	RMSE
LSTM	۰.۹۲۸	—	۳۸۵۵۶۱۵.۸۱۵	۴۶۷۸۱۵۰.۱۶۷
SARIMA	—	۱۰.۱۸۷۳۶۸۴۰۳۳۳۶٪	۴۹۱۵۲۹۲.۲۲۴۷۰۰۸	۳۴۵۲۳۵۶۸۸۶۳۰۸ ۹.۶۵۲

شکل ۴-۱۳: مقایسه مقادیر معیار های عملکردی برای هر دو الگوریتم LSTM و SARIMA



شکل ۴-۱۴: نمودار RIGOR خلاصه مراحل اجرای دو الگوریتم LSTM و SARIMA

۴-۴ جمع بندی

امروزه پیش بینی مصرف انرژی رکن اصلی تصمیمات مدیریتی در صرفه جویی در مصرف انرژی محسوب میشود. پیش بینی مصرف گاز نیز در مدیریت و تنظیم مصرف برای سال های آینده به خصوص در فصول سرد سال امری ضروری است. هدف اصلی این پژوهش پیش بینی و تحلیل مصرف گاز مشترکین خانگی شهر اراک بوده است با توجه به تعریف مسئله مورد نظر هدف این پژوهش بررسی و تحلیل مصرف گاز در سری زمانی چند متغیره بوده که عوامل خارجی نیز در نظر گرفته شده.

۴-۵ نتایج پژوهش

در این پژوهش قابلیت های مدل یادگیری عمیق برای پیش بینی مصرف با دیگر مدل کلاسیک مطرح شده. پس از انجام پیش بینی مصرف نتایج زیر از این مطالعه استخراج میشود. روش های شبکه عصبی اغلب بهتر از روش پیش بینی کلاسیک عمل کرده اند. در مسئله سری زمانی چند متغیره در حوزه یک و دو در هر دو روش LSTM بهتر از روش SARIMA عمل کرده. لازم به ذکر است که در حوزه دوم تعداد مشترکین خانگی به طور قابل توجهی کمتر از حوزه اول بوده است و در نتیجه داده های پراکنده ای از حوزه ۲ در دسترس است. در نهایت این نکته را میتوان بیان کرد که نتایج بدست آمده در این پژوهش ملاکی بر ضعف عملکردی مدل کلاسیک SARIMA در مسئله سری زمانی مورد نظر و همچنین برتری مدل LSTM نخواهد بود دلیل این امر آن است که نتایج خروجی مدل های بررسی شده به شدت به کیفیت مجموعه داده ها و معماری مدل ها و همچنین نحوه پیاده سازی آنها بستگی دارد.

اهمیت پژوهش

این پژوهش به پیش‌بینی مصرف گاز مشترکین خانگی با بهره‌گیری از روش‌های نوین یادگیری عمیق، به‌عنوان بخشی از حوزه‌های یادگیری ماشین و هوش مصنوعی، پرداخته است. به‌کارگیری این رویکردها موجب افزایش دقت در پیش‌بینی می‌شود و این دقت بالا برای مدیران و برنامه‌ریزان بخش انرژی، به‌ویژه در حوزه برنامه‌ریزی مصرف مشترکین خانگی، اهمیت ویژه‌ای دارد.

هدف نهایی این پژوهش، کمک به بهینه‌سازی تخصیص منابع گاز طبیعی در سطح ملی است. از آنجا که ظرفیت استخراج گاز محدود است، اولویت شرکت ملی گاز، تأمین نیاز صنایع و کارخانه‌ها به‌منظور پشتیبانی از چرخه تولید و جلوگیری از وقفه در فعالیت‌های اقتصادی است. در این راستا، دسترسی به پیش‌بینی دقیق مصرف سال‌های آینده مشترکین خانگی، امکان برنامه‌ریزی و تقسیم‌بندی بهینه سهم گاز میان خانوارها و صنایع را فراهم می‌سازد. تحقق این امر می‌تواند سهم گاز تخصیص‌یافته به صنایع و شرکت‌ها را افزایش داده و در نهایت به رشد تولید، پایداری فعالیت‌های صنعتی و رونق اقتصادی کشور منجر شود.

مراجع

- [1] ناجی میدانی, رحیمی, & غلامعلی. (۲۰۱۵). تعیین اولویت بازارهای صادراتی گاز طبیعی ایران. *فصلنامه مطالعات اقتصاد انرژی*, ۱۱ (۴۶), ۱۸۱-۲۱۹.
- [2] اعظمی, آزاده, میرک زاده, & آذری. (۲۰۲۴). بهینه‌سازی الگوی کشت محصولات زراعی شهرستان صحنه براساس محدودیت منابع. *جغرافیا و برنامه ریزی محیطی*, ۳۵ (۲), ۸۷-۱۱۴.
- [3] داغبندان, الهیار, ستایش, & نسا. (۲۰۱۷). مدل‌سازی و پیش‌بینی میزان مصرف گاز طبیعی به کمک شبکه های عصبی نوع GMDH چندهدفی. *مطالعه موردی: شرکت گاز شهر رشت. نشریه انرژی ایران*, ۱۹ (۴), ۰-۰.
- [4] شفیعی نیک آبادی, & عظیمی. (۲۰۱۵). پیش بینی تقاضا در زنجیره تامین با استفاده از الگوریتم های یادگیری ماشین (مورد مطالعه: زنجیره تامین شرکت ایران خودرو). *مدل سازی در مهندسی*, ۱۳ (۴۱), ۱۲۷-۱۳۶.
- [5] شفیعی شهران, & برادران وحید. (۲۰۲۰). توسعه مدل رگرسیون زنجیره مارکوف خاکستری و پیش بینی مصرف سالیانه گاز کشور.
- [6] Liu, L. M., & Lin, M. W. (1991). Forecasting residential consumption of natural gas using monthly and quarterly time series. *International Journal of Forecasting*, 7(1), 3-16.
- [7] Gil, S., & Deferrari, J. (2004). Generalized model of prediction of natural gas consumption. *J. Energy Resour. Technol.*, 126(2), 90-98.
- [8] Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018). Statistical and Machine Learning forecasting methods: Concerns and ways forward. *PloS one*, 13(3), e0194889.
- [9] Nenni, M. E., Giustiniano, L., & Pirolo, L. (2013). Demand forecasting in the fashion industry: a review. *International Journal of Engineering Business Management*, 5, 37.
- [10] Chopra, S., & Meindl, P. (2007). *Supply chain management. Strategy, planning & operation* (pp. 265-275). Gabler.
- [11] Reiner, G., & Fichtinger, J. (2009). Demand forecasting for supply processes in consideration of pricing and market information. *International Journal of Production Economics*, 118(1), 55-62.
- [12] Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: principles and practice*. OTexts.
- [13] Fildes, R., Ma, S., & Kolassa, S. (2022). Retail forecasting: Research and practice. *International Journal of Forecasting*, 38(4), 1283-1318.
- [14] Lazo, J.K., et al., US economic sensitivity to weather variability. *Bulletin of the American Meteorological Society*, 2011. 92(6): p. 709-720.
- [15] Ensafi, Y., Amin, S. H., Zhang, G., & Shah, B. (2022). Time-series forecasting of seasonal items sales using machine learning—A comparative analysis. *International Journal of Information Management Data Insights*, 2(1), 100058.

- [16] Michalski, R. S., Carbonell, J. G., & Mitchell, T. M. (Eds.). (2013). *Machine learning: An artificial intelligence approach*. Springer Science & Business Media.
- [17] Brockwell, P. J., & Davis, R. A. (Eds.). (2002). *Introduction to time series and forecasting*. New York, NY: Springer New York.
- [18] Huang, C., & Petukhina, A. (2022). *Applied time series analysis and forecasting with Python*. Cham: Springer.
- [19] Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: principles and practice*. OTexts.
- [20] Anderson, D. R., Williams, T. A., & Cochran, J. J. (2020). *Statistics for business & economics*. Cengage Learning.

پیوست ها

کد پایتون مورد استفاده در سری زمانی چند متغیره

```
import pandas as pd
df = pd.read_excel(r"C:\Users\ASUS\Desktop\weather2.xlsx")
from collections import defaultdict

grouped_cols = defaultdict(list)

for col in df.columns:
    base_name = col.split('.')[0]
    grouped_cols[base_name].append(col)

final_df = {}

for name, cols in grouped_cols.items():
    combined = pd.concat([df[col] for col in cols], ignore_index=True)
    final_df[name] = combined

final_df = pd.DataFrame(final_df)
print(final_df.head())
final_df.to_excel("result_stacked.xlsx", index=False)

import pandas as pd
from persiantools.jdatetime import JalaliDate

df = pd.read_excel(r"C:\Users\ASUS\Desktop\weather2.xlsx")
df['ماه'] = df['ماه'].astype(int).astype(str).str.zfill(2)

df['سال'] = df['سال'].astype(int).astype(str)

df['تاریخ'] = df['سال'] + '-' + df['ماه']
# print(df[['سال', 'ماه', 'تاریخ']])
df['شمسی تاریخ'] = pd.to_datetime(df['تاریخ']).apply(lambda x: JalaliDate(x).strftime('%Y-%m'))
print(df['شمسی تاریخ'])
df.to_excel("C:\\Users\\ASUS\\Desktop\\weather2.xlsx", index=False)

# -*- coding: utf-8 -*-

import os

import glob

import re

import numpy as np

import pandas as pd

import matplotlib.pyplot as plt

import random

from sklearn.preprocessing import MinMaxScaler

from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
```

```

from tensorflow.keras.models import Model
from tensorflow.keras.layers import Input, LSTM, Dense, Dropout
from tensorflow.keras.optimizers import Adam
from tensorflow.keras.callbacks import EarlyStopping, ReduceLROnPlateau

SEED = 42
np.random.seed(SEED)
random.seed(SEED)
import tensorflow as tf
tf.random.set_seed(SEED)

input_path = r"/content/کامل.xlsx"
output_folder = r"D:\LSTM"
os.makedirs(output_folder, exist_ok=True)

def find_excel_file(base_path):
    if os.path.isfile(base_path):
        return base_path
    for ext in ['.xlsx', '.xls', '.xlsm']:
        candidate = base_path + ext
        if os.path.isfile(candidate):
            return candidate
    if os.path.isdir(base_path):
        files = glob.glob(os.path.join(base_path, "*.xlsx")) + glob.glob(os.path.join(base_path, "*.xls"))
        if len(files) > 0:
            return files[0]
    raise FileNotFoundError(f"فایل اکسل در مسیر '{base_path}' پیدا نشد. لطفاً مسیر/نام فایل را بررسی کنید")

excel_file = find_excel_file(input_path)
print("Using input file:", excel_file)

df = pd.read_excel(excel_file)

def clean_weather_value(x):
    if pd.isnull(x):
        return np.nan

```

```

s = str(x).strip()
if s in ['-','—',' ','NA','N/A','nan']:
    return np.nan

match = re.search(r'[-?]\d+(\.\d+)?', s.replace(',', ''))
return float(match.group()) if match else np.nan

weather_features = ['High Temp', 'Low Temp', 'Avg Temp', 'Rainfall']
target_1 = 'حوزه ۱'
target_2 = 'حوزه ۲'
date_col_candidates = ['تاریخ', 'Date', 'date', 'datetime']

date_col = None
for c in date_col_candidates:
    if c in df.columns:
        date_col = c
        break
if date_col is None:
    raise KeyError("ستون تاریخ پیدا نشد. لطفا ستون تاریخ را با نام 'تاریخ' در فایل قرار دهید")

for col in weather_features:
    if col in df.columns:
        df[col] = df[col].apply(clean_weather_value)
    else:
        raise KeyError(f"ستون ویژگی '{col}' نام ستونها را بررسی کنید '{col}'")

for t in [target_1, target_2]:
    if t not in df.columns:
        raise KeyError(f"پیدا نشد. نام ستونها را بررسی کنید '{t}' ستون هدف")

df[date_col] = pd.to_datetime(df[date_col], errors='coerce')
df = df.dropna(subset=[date_col])
df = df.sort_values(by=date_col).reset_index(drop=True)
df.set_index(date_col, inplace=True)

if 'ماه' not in df.columns:
    df['ماه'] = df.index.month

```

```

if 'سال' not in df.columns:
    df['سال'] = df.index.year

df['month_sin'] = np.sin(2 * np.pi * df.index.month / 12)
df['month_cos'] = np.cos(2 * np.pi * df.index.month / 12)

#**برای حوزه‌ها (مصرف ماه‌های قبلی) lag افزودن ویژگی**
lag_months = [1,2,3]
for lag in lag_months:
    df[f'{target_1}_lag{lag}'] = df[target_1].shift(lag)
    df[f'{target_2}_lag{lag}'] = df[target_2].shift(lag)

# lag دارند به خاطر NaN حذف ردیف‌هایی که
features = weather_features + ['month_sin', 'month_cos']
lag_features = [f'{target_1}_lag{lag}' for lag in lag_months] + [f'{target_2}_lag{lag}' for lag in lag_months]
all_features = features + lag_features

df = df.dropna(subset=all_features + [target_1, target_2]).copy()

sequence_length = 18
if len(df) <= sequence_length:
    raise ValueError(f"تعداد ردیف‌های مفید ({len(df)}) کمتر یا مساوی طول دنباله ({sequence_length}) است.")

monthly_climatology = df[weather_features].groupby(df.index.month).mean()
for col in weather_features:
    monthly_climatology[col] = monthly_climatology[col].fillna(df[col].mean())

X_all = df[all_features].values
y_all = df[[target_1, target_2]].values

scaler_X = MinMaxScaler()
scaler_y = MinMaxScaler()

X_scaled_all = scaler_X.fit_transform(X_all)
y_scaled_all = scaler_y.fit_transform(y_all)

```

```

def create_sequences(X, y, seq_len):
    X_seq, y_seq = [], []
    for i in range(seq_len, len(X)):
        X_seq.append(X[i-seq_len:i])
        y_seq.append(y[i])
    return np.array(X_seq), np.array(y_seq)

X_seq, y_seq = create_sequences(X_scaled_all, y_scaled_all, sequence_length)

split_index = int(len(X_seq) * 0.75)
X_train, X_test = X_seq[:split_index], X_seq[split_index:]
y_train, y_test = y_seq[:split_index], y_seq[split_index:]

print("Train shape:", X_train.shape, y_train.shape, "Test shape:", X_test.shape, y_test.shape)

def build_lstm_multiooutput(input_shape, units=256, lr=3e-4):
    inputs = Input(shape=input_shape)
    x = LSTM(units, return_sequences=True)(inputs)
    x = Dropout(0.2)(x)
    x = LSTM(units//2)(x)
    x = Dropout(0.2)(x)
    outputs = Dense(2)(x) # دو خروجی حوزه‌ها
    model = Model(inputs, outputs)
    model.compile(optimizer=Adam(learning_rate=lr), loss='mse')
    return model

model = build_lstm_multiooutput((sequence_length, X_train.shape[2]), units=256, lr=3e-4)

es = EarlyStopping(monitor='val_loss', patience=30, restore_best_weights=True, verbose=1)
rlrop = ReduceLROnPlateau(monitor='val_loss', factor=0.5, patience=10, min_lr=1e-6, verbose=1)

epochs = 300
batch_size = 16

history = model.fit(
    X_train, y_train,

```



```

validation_data=(X_test, y_test),
epochs=epochs, batch_size=batch_size,
callbacks=[es, rdrop],
shuffle=False,
verbose=2
)

```

ارزیابی

```

def evaluate_and_print_multioutput(model, X_test, y_test_scaled, scaler_y):
    y_pred_scaled = model.predict(X_test)
    y_pred = scaler_y.inverse_transform(y_pred_scaled)
    y_true = scaler_y.inverse_transform(y_test_scaled)
    results = []
    for i, area in enumerate(['حوزه ۱', 'حوزه ۲']):
        mae = mean_absolute_error(y_true[:,i], y_pred[:,i])
        rmse = np.sqrt(mean_squared_error(y_true[:,i], y_pred[:,i]))
        try:
            r2 = r2_score(y_true[:,i], y_pred[:,i])
        except:
            r2 = np.nan
        print(f"--- Evaluation {area} ---")
        print(f"MAE: {mae:.3f}, RMSE: {rmse:.3f}, R2: {r2:.3f}")
        results.append((mae, rmse, r2))
    return y_true, y_pred, results

```

```

y_true, y_pred, eval_results = evaluate_and_print_multioutput(model, X_test, y_test, scaler_y)

```

```

plt.figure(figsize=(14,5))
plt.subplot(1,2,1)
plt.plot(y_true[:,0], label='واقعی - حوزه ۱')
plt.plot(y_pred[:,0], label='پیش‌بینی - حوزه ۱')
plt.title("مقایسه واقعی و پیش‌بینی - حوزه ۱ (مجموعه تست)")
plt.legend(); plt.grid(True)

plt.subplot(1,2,2)

```

```
plt.plot(y_true[:,1], label='حوزه واقعی - ۲')
plt.plot(y_pred[:,1], label='پیش‌بینی - حوزه ۲')
plt.title("مقایسه واقعی و پیش‌بینی - حوزه ۲ (مجموعه تست)")
plt.legend(); plt.grid(True)
plt.tight_layout()
plt.show()
```

های پیش‌بینی شده برای حوزه‌ها lag بهبود تابع پیش‌بینی چندماهه با استفاده از

```
def make_future_feature_vector_from_climatology_and_preds(last_date, step_ahead_months, prev_preds_area1,
prev_preds_area2):
```

```
    target_month = ((last_date.month - 1 + step_ahead_months) % 12) + 1
    weather_vec = monthly_climatology.loc[target_month, weather_features].values
    month_sin = np.sin(2 * np.pi * target_month / 12)
    month_cos = np.cos(2 * np.pi * target_month / 12)
```

مقدارها را از پیش‌بینی‌های قبلی با آخرین مقادیر واقعی می‌گیریم lag برای

```
# lag1 = مقدار (step_ahead_months-1) ماه قبل
# lag2 = مقدار (step_ahead_months-2) دو ماه قبل
# lag3 = مقدار (step_ahead_months-3) سه ماه قبل
```

```
def get_lag_value(lag):
```

```
    idx = step_ahead_months - lag - 1
    if idx >= 0:
        return prev_preds_area1[idx], prev_preds_area2[idx]
    else:
        # بیشتر از تعداد پیش‌بینی‌ها بود، مقدار ۰ یا مقدار آخر واقعی را برگردان lag اگر
        return prev_preds_area1[0], prev_preds_area2[0]
```

```
lag1_a1, lag1_a2 = get_lag_value(1)
```

```
lag2_a1, lag2_a2 = get_lag_value(2)
```

```
lag3_a1, lag3_a2 = get_lag_value(3)
```

```
return np.array(list(weather_vec) + [month_sin, month_cos, lag1_a1, lag2_a1, lag3_a1, lag1_a2, lag2_a2, lag3_a2])
```

```
def multi_step_forecast_multioutput(model, scaler_X, scaler_y, last_sequence_scaled, last_date, steps):
```

```
    preds_scaled = []
    input_seq = last_sequence_scaled.copy()
```

```

preds_area1 = []
preds_area2 = []
for step in range(1, steps+1):
    pred_scaled = model.predict(input_seq.reshape(1, *input_seq.shape), verbose=0)[0]
    preds_scaled.append(pred_scaled)
    pred_inv = scaler_y.inverse_transform(pred_scaled.reshape(1,-1)).flatten()
    preds_area1.append(pred_inv[0])
    preds_area2.append(pred_inv[1])

future_feat = make_future_feature_vector_from_climatology_and_preds(last_date, step, preds_area1, preds_area2)
future_feat_scaled = scaler_X.transform(future_feat.reshape(1,-1)).reshape(-1)

input_seq = np.vstack([input_seq[1:], future_feat_scaled])
preds_scaled = np.array(preds_scaled)
preds = scaler_y.inverse_transform(preds_scaled)
preds[:,0] = np.maximum(preds[:,0], 0)
preds[:,1] = np.maximum(preds[:,1], 0)
return preds

last_seq = X_seq[-1]
last_date = df.index[-1]

future_steps = 6
future_preds = multi_step_forecast_multiooutput(model, scaler_X, scaler_y, last_seq, last_date, future_steps)

months = pd.date_range(start=last_date + pd.offsets.MonthBegin(), periods=future_steps, freq='MS')

plt.figure(figsize=(14,6))
plt.plot(months, future_preds[:,0], label='پیش‌بینی حوزه ۱')
plt.plot(months, future_preds[:,1], label='پیش‌بینی حوزه ۲')
plt.title("پیش‌بینی ۳۶ ماه آینده برای حوزه ۱ و حوزه ۲")
plt.legend()
plt.grid(True)
plt.show()
import seaborn as sns
import numpy as np

```

```

محاسبه ماتریس همبستگی فقط برای ستون‌های عددی #
df_numeric = df.select_dtypes(include=np.number)
correlation_matrix = df_numeric.corr()

plt.figure(figsize=(12,10))
sns.heatmap(correlation_matrix, annot=True, fmt=".2f", cmap='Blues', linewidths=0.5)
plt.title("ماتریس همبستگی ویژگی‌ها و مقادیر هدف")
plt.show()

import seaborn as sns
from sklearn.metrics import r2_score, mean_absolute_error, mean_squared_error

# y_true و y_pred (ارزیابی مجموعه تست)
# برای حوزه ۱
area_names = ['حوزه ۱', 'حوزه ۲']

for i, area in enumerate(area_names):
    print(f"--- نتایج حوزه {area} ---")
    y_t = y_true[:, i]
    y_p = y_pred[:, i]

    mae = mean_absolute_error(y_t, y_p)
    rmse = np.sqrt(mean_squared_error(y_t, y_p))
    r2 = r2_score(y_t, y_p)

    print(f"MAE: {mae:.4f}")
    print(f"RMSE: {rmse:.4f}")
    print(f"R2: {r2:.4f}")

plt.figure(figsize=(6,6))
sns.scatterplot(x=y_t, y=y_p, alpha=0.6)
plt.plot([min(y_t), max(y_t)], [min(y_t), max(y_t)], 'r--')
plt.xlabel('مقادیر واقعی')
plt.ylabel('مقادیر پیش‌بینی شده')
plt.title(f'{area} - پیش‌بینی vs واقعی Scatter نمودار')
plt.grid(True)
plt.show()

```

```

corr = np.corrcoef(y_t, y_p)[0,1]
print(f"Correlation بین واقعی و پیش‌بینی برای {area}: {corr:.4f}")
print("\n")
import warnings
warnings.filterwarnings("ignore")
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from statsmodels.tsa.statespace.sarimax import SARIMAX
from statsmodels.tsa.stattools import adfuller, acf, pacf
from sklearn.metrics import mean_squared_error, mean_absolute_error
path = "/content/کامل.xlsx"
df = pd.read_excel(path)
col_year = None
col_month = None
col_target = None
for c in df.columns:
    if str(c).strip() in ["سال", "year", "Year"]:
        col_year = c
    if str(c).strip() in ["ماه", "month", "Month"]:
        col_month = c
    if str(c).strip() in ["حوزه ۱", "حوزه ۲", "hoze1", "Zone 1", "Domain 1"]:
        col_target = c
if col_target is None:
    num_cols = df.select_dtypes(include=np.number).columns.tolist()
    if len(num_cols) == 0:
        raise ValueError("ستون عددی برای هدف پیدا نشد")
    col_target = num_cols[-1]

if col_year is None or col_month is None:
    # Try to infer a datetime column if year/month missing
    dt_cols = [c for c in df.columns if pd.api.types.is_datetime64_any_dtype(df[c])]
    if dt_cols:
        dt_col = dt_cols[0]
        df["تاریخ"] = pd.to_datetime(df[dt_col])

```

```

else:
    # last resort: try to parse from first column
    first = df.columns[0]
    try:
        df["تاریخ"] = pd.to_datetime(df[first])
    except Exception:
        raise ValueError("ستون های سال/ماه یا تاریخ پیدا نشدند.")
else:
    df["تاریخ"] = pd.to_datetime(df[col_year].astype(str) + "-" + df[col_month].astype(str), format="%Y-%m")
df = df.sort_values("تاریخ")
df = df.set_index("تاریخ")
df = df.asfreq("MS")
series = df[col_target].astype(float).dropna()
series.index = pd.to_datetime(series.index)
series = series.asfreq("MS")
def adf_pval(s):
    s = s.dropna()
    if len(s) < 10:
        return np.nan
    try:
        return adfuller(s, autolag="AIC")[1]
    except Exception:
        return np.nan
p_values = [0,1,2]
d_values = [0,1]
q_values = [0,1,2]
P_values = [0,1]
D_values = [0,1]
Q_values = [0,1]
s = 12
best = {"aic": np.inf, "order": None, "seasonal_order": None, "res": None}

for d in d_values:
    for D in D_values:
        for p in p_values:
            for q in q_values:

```

```

for P in P_values:
    for Q in Q_values:
        order = (p, d, q)
        seasonal_order = (P, D, Q, s)
        try:
            model = SARIMAX(train, order=order, seasonal_order=seasonal_order,
                             enforce_stationarity=False, enforce_invertibility=False)
            res = model.fit(dispatch=False)
            if res.aic < best["aic"]:
                best = {"aic": res.aic, "order": order, "seasonal_order": seasonal_order, "res": res}
        except Exception:
            continue
    best_order = best["order"]
    best_seasonal_order = best["seasonal_order"]
    res = best["res"]
    steps = len(test)
    fc = res.get_forecast(steps=steps)
    fc_mean = fc.predicted_mean
    fc_ci = fc.conf_int()
    rmse = mean_squared_error(test, fc_mean)
    mae = mean_absolute_error(test, fc_mean)
    mape = (np.abs((test - fc_mean) / test).replace([np.inf, -np.inf], np.nan).dropna() * 100).mean()
    full_model = SARIMAX(series, order=best_order, seasonal_order=best_seasonal_order,
                          enforce_stationarity=False, enforce_invertibility=False)
    full_res = full_model.fit(dispatch=False)

    future_steps = 12
    future_fc = full_res.get_forecast(steps=future_steps)
    future_mean = future_fc.predicted_mean
    future_ci = future_fc.conf_int()
    summary_info = {
        "best_order": best_order,
        "best_seasonal_order": best_seasonal_order,
        "best_aic": best["aic"],
        "adf_pvalue_train": adf_pval(train),
        "adf_pvalue_diff1": adf_pval(train.diff()),
    }

```

```

"adf_pvalue_seasonal_diff": adf_pval(train.diff(12)),
"rmse_test": rmse,
"mae_test": mae,
"mape_test_percent": mape
}
summary_df = pd.DataFrame([summary_info])
summary_df
out = pd.DataFrame({
    "actual_test": test,
    "pred_test": fc_mean.reindex(test.index)
})
out_future = pd.DataFrame({
    "forecast_mean": future_mean,
    "lower": future_ci.iloc[:,0],
    "upper": future_ci.iloc[:,1]
})
summary_path = (r"C:\Users\ASUS\Desktop\sarima_summary.xlsx")
test_fc_path = (r"C:\Users\ASUS\Desktop\sarima_test_forecast.xlsx")
future_fc_path = (r"C:\Users\ASUS\Desktop\sarima_future12.xlsx")
summary_df.to_csv(summary_path, index=False)
out.to_csv(test_fc_path)
out_future.to_csv(future_fc_path)
plt.figure(figsize=(12,6))
plt.plot(train.index, train, label="Train")
plt.plot(test.index, test, label="Test")
plt.plot(fc_mean.index, fc_mean, label="Forecast (Test)")
plt.fill_between(fc_ci.index, fc_ci.iloc[:,0], fc_ci.iloc[:,1], alpha=0.25, label="95% CI")
plt.legend()
plt.title("SARIMA: Train/Test Forecast")
plt.figure(figsize=(12,6))
plt.plot(series.index, series, label="History")
plt.plot(future_mean.index, future_mean, label="Forecast (Next 12)")
plt.fill_between(future_ci.index, future_ci.iloc[:,0], future_ci.iloc[:,1], alpha=0.25, label="95% CI")
plt.legend()
plt.title("SARIMA: Next 12 Months Forecast")

```

استفاده می‌کنیم infer_freq یا asfreq مستقیم، از freq کردن set مشکل به خاطر گپ یا ترتیب تاریخ‌هاست. به جای #


```

import pandas as pd
import matplotlib.pyplot as plt
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf

# بارگذاری داده‌ها
target = pd.read_excel("/content/کامل.xlsx")

# ساخت ستون تاریخ
target['تاریخ'] = pd.to_datetime(target['سال'].astype(str) + '-' + target['ماه'].astype(str), format='%Y-%m')
target = target.sort_values('تاریخ')
target.set_index('تاریخ', inplace=True)

# تلاش برای شناسایی فرکانس
try:
    target.index.freq = pd.infer_freq(target.index)
except:
    target = target.asfreq('MS')

# انتخاب سری حوزه ۱
y = target['۱ حوزه'].dropna()

# رسم نمودار ACF و PACF
fig, axes = plt.subplots(2, 1, figsize=(12, 8))
plot_acf(y, lags=48, ax=axes[0])
plot_pacf(y, lags=48, ax=axes[1])
axes[0].set_title("ACF - ۱ حوزه")
axes[1].set_title("PACF - ۱ حوزه")
plt.tight_layout()
plt.show()

x1 = fc_mean.index
y1 = fc_ci.iloc[:, 0].astype(float).values
y2 = fc_ci.iloc[:, 1].astype(float).values
plt.figure(figsize=(12,6))
plt.plot(train.index, train, label="Train")
plt.plot(test.index, test, label="Test")

```

```

plt.plot(fc_mean.index, fc_mean, label="Forecast (Test)")
plt.fill_between(x1, y1, y2, alpha=0.25, label="95% CI")
plt.legend()
plt.title("SARIMA: Train/Test Forecast")
plt.show()

x2 = future_mean.index
y1f = future_ci.iloc[:, 0].astype(float).values
y2f = future_ci.iloc[:, 1].astype(float).values

plt.figure(figsize=(12,6))
plt.plot(series.index, series, label="History")
plt.plot(future_mean.index, future_mean, label="Forecast (Next 12)")
plt.fill_between(x2, y1f, y2f, alpha=0.25, label="95% CI")
plt.legend()
plt.title("SARIMA: Next 12 Months Forecast")
plt.show()

print("Best order:", best_order)
print("Best seasonal order:", best_seasonal_order)
print("Test RMSE:", rmse)
print("Test MAE:", mae)
print("Test MAPE (%):", mape)

```